API Ceris BI IA

Observabilidade do grafo de agentes · Mongo para a página, LangSmith para a seção 04

`application="bi-ia"` `Período: 26 out 2026 – 02 nov 2026`

Resumo do período

26 out 2026 – 02 nov 2026 · 29 execuções · mesma base dos gráficos e do relatório

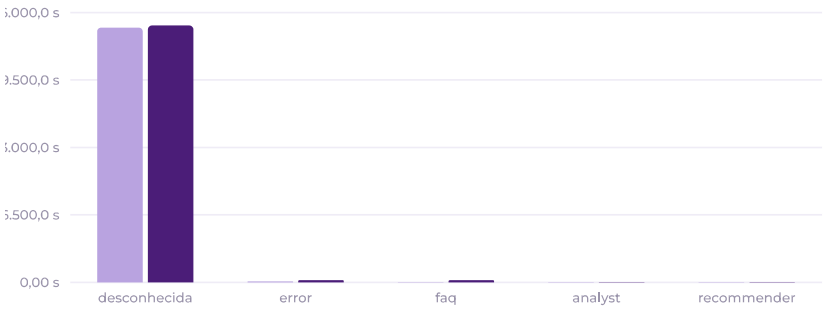
29	24.555,2 s	US$ 0,00	65,52%	0,00%
Execuções	p95 E2E	Custo total	Taxa de erro	Devoluções do juiz

01 Performance

Latência por rota, decomposição por nó e leitura de nota

Latência E2E por rota

segundos · p50 e p95 em séries distintas

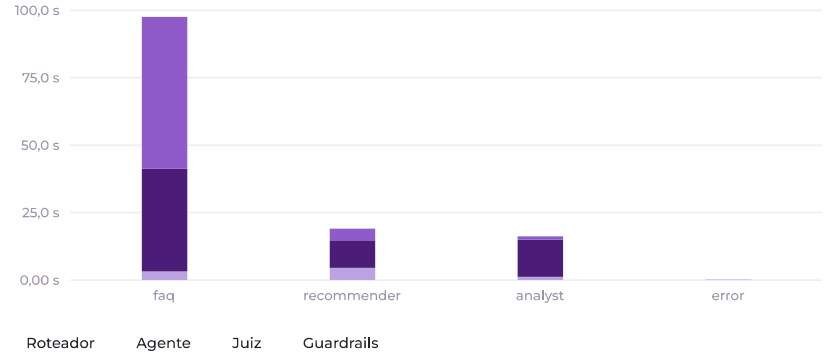


Volume por rota: desconhecida 3 · error 19 · faq 2 · analyst 4 · recommender 1

`metrics · duration_ms por rota`

Latência média por nó · empilhada

segundos · contribuição de cada etapa por rota



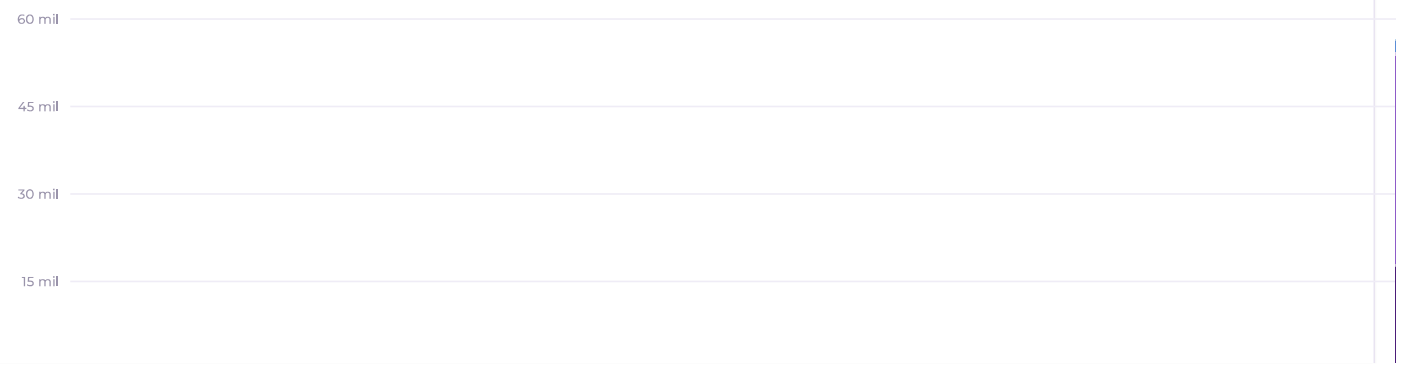
`Soma das etapas = média E2E da rota, não soma de percentis`

02 Custo e capacidade

Tokens por dia e rota, custo por modelo e limites do Gemini

Tokens de entrada + saída por dia e rota

mil tokens · 71,54 mil no período · 68,85 mil input + 2,7 mil output





analyst · input analyst · output recommender · input recommender · output error · input error · output desconhecida · input desconhecida · output faq · input faq · output

Pico: 01 nov · 56,47 mil

Custo diário por modelo

USD · total US$ 0,00 · preços estimados



gemini-3.8-flash

gemini-3.8-flash US$ 0,00

Gemini 429 · erros por hora

últimas 24 h · total 0 · período 1

Nenhum 429 nas últimas 24 horas.

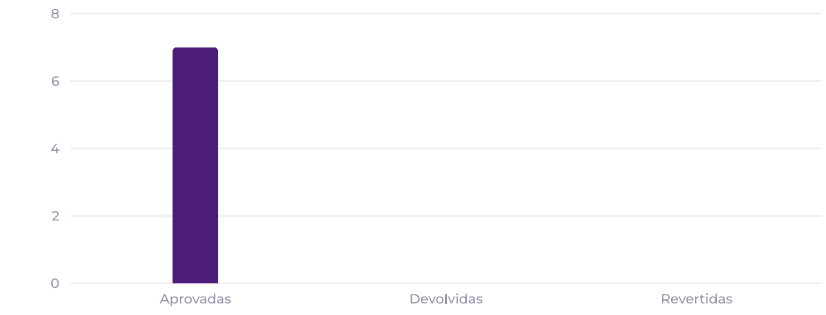
Conta o 429 que chegou ao fim da requisição. O que o retry absorveu vira latência.

03 Qualidade e ferramentas

Decisões do juiz, bloqueios de guardrails e confiabilidade das tools

Decisões do juiz

7 decisões · uma por leitura do juiz



7 (100%) aprovadas · 0 (0%) devolvidas · 0 (0%) revertidas pela segunda opinião

Bloqueios de guardrails

contagem por estágio · 0 bloqueios no período

Nenhum bloqueio no período.

0,00% de 29 execuções; não são erros de tool

Ferramentas · chamadas, erros e duração média

Mesmos nomes do relatório

Tool	Chamadas	Erros	Taxa de erro	Média (ms)	p95 (ms)
search_reports_by_period	3	0	0,00%	1.967	4.422
get_latest_reports	2	0	0,00%	1.779	3.154

04 LangSmith

Execuções e erros por dia, percentis por chain e por agente

LangSmith indisponível

LangSmithError: Failed to POST /runs/query in LangSmith API. HTTPError('400 Client Error: Bad Request for url: https://api.smith.langchain.com/runs/query', '{"detail":"Limit exceeds maximum allowed value of 100"}')

05 Relatório do período

Resumo visível · período atual contra o anterior de mesmo tamanho

Relatório · API Ceris BI IA

Atual 26 out 2026 – 02 nov 2026 contra 19 out 2026 – 26 out 2026 · gerado às 22:38

Imprimir

Indicador	Atual	Anterior	Variação
Volume total	29	0	—
Latência p95 E2E	24.555,2 s	0,00 s	—
Custo total	US$ 0,00	US$ 0,00	—
Taxa de erro	65,52%	0,00%	+65,52 p.p.
Devoluções do juiz	0,00%	0,00%	0,00 p.p.

Top 3 rotas mais lentas · p95

1. desconhecida · 24.749,5 s
2. error · 204,3 s
3. faq · 192,1 s

Top 3 tools com maior taxa de erro

Nenhuma tool falhou no período.

Consumo: 71,54 mil tokens (68,85 mil input + 2,7 mil output). Pico diário 56,47 mil em 01 nov. Juiz: 7 decisões.